

طبقه‌بندی گریه نوزاد با استفاده از شبکه‌های عصبی مصنوعی تنظیم‌شده ساختاری،

افزایش داده و ویژگی‌های MFCC

طیب اوزجان و حفیظه گونگور

ویژه‌نامه: یادگیری ماشین و یادگیری عمیق در پردازش سیگنال، ویرایش دوم

ویراستاران: دکتر مارا پیستلاتو و پروفیسور دکتر بیونگ-گیو کیم

چکیده: نوزادان نیازهای خود مانند گرسنگی، ناراحتی یا بی‌خوابی را از طریق گریه بیان می‌کنند. با این حال، درک صحیح این گریه‌ها برای والدین می‌تواند چالش‌برانگیز باشد. این امر می‌تواند پاسخ‌گویی به نیازهای نوزاد را به تأخیر بیندازد، سطح استرس والدین را افزایش دهد و بر رشد نوزاد تأثیر منفی بگذارد. در این مقاله، یک سیستم یکپارچه برای طبقه‌بندی صداهای نوزاد پیشنهاد شده است. روش پیشنهادی شامل مراحل افزایش داده، استخراج ویژگی، تنظیم فرایارامتر و آموزش مدل است. در مرحله اول، تکنیک‌های مختلف افزایش داده برای افزایش تنوع داده‌های آموزشی و تقویت ظرفیت تعمیم‌پذیری مدل به کار گرفته شد. در مرحله دوم، از روش MFCC (ضرایب کپسترالی مل-فرکانسی) برای استخراج ویژگی‌های معنادار و متمایزکننده از داده‌های صوتی استفاده شد. MFCC سیگنال‌های صوتی را بر اساس فرکانس‌های درک‌شده توسط گوش انسان نمایش می‌دهد و مبنای قدرتمندی برای طبقه‌بندی فراهم می‌کند. ویژگی‌های به‌دست‌آمده با یک مدل شبکه عصبی مصنوعی (ANN) با فرایارامترهای بهینه‌شده طبقه‌بندی شدند. بهینه‌سازی فرایارامترهای مدل با استفاده از الگوریتم جستجوی شبکه‌ای (grid search) انجام شد و مناسب‌ترین پارامترها تعیین گردید. مجموعه‌های داده‌ی آموزش، اعتبارسنجی و آزمون به ترتیب با نسبت‌های ۷۵٪، ۱۰٪ و ۱۵٪ تفکیک شدند. عملکرد مدل بر روی صداهای ترکیبی آزمون شد. نتایج آزمون تحلیل گردید و روش پیشنهادی با نرخ دقت ۹۰٪ بالاترین عملکرد را نشان داد. در مطالعه مقایسه‌ای با یک شبکه عصبی مصنوعی (ANN) بر روی مجموعه داده Donate a Cry، نمره F1 به میزان ۹۹/۴۶٪ و دقت آزمون ۹۳/۸۵٪ گزارش شده بود. در این مقاله، تکنیک‌های اضافی مانند افزایش داده، تنظیم فرایارامتر و استخراج ویژگی MFCC باعث شد دقت مدل به ۹۰٪ برسد. روش پیشنهادی راه‌حلی مؤثر برای طبقه‌بندی صداهای نوزاد ارائه می‌دهد و رویکرد جدیدی به این حوزه می‌آورد.

واژگان کلیدی: طبقه‌بندی گریه نوزاد؛ ضرایب کپسترالی مل-فرکانسی؛ افزایش داده؛ بهینه‌سازی جستجوی شبکه‌ای؛ شبکه عصبی مصنوعی

مقدمه

نوزادان به‌عنوان یک بازتاب ذاتی برای بیان نیازهای خود مانند گرسنگی، ناراحتی و بی‌خوابی گریه می‌کنند. درک صحیح و سریع این گریه‌ها برای رشد سالم و شادابی نوزادان حیاتی است. با این حال، والدین بی‌تجربه، مراقبان جدید و برخی از متخصصان مراقبت‌های بهداشتی ممکن است در درک دلیل گریه نوزادان دچار مشکل شوند. این امر می‌تواند منجر به گریه طولانی‌مدت، افزایش سطح استرس و تأثیر منفی بر رشد شناختی شود.

مطالعات انجام‌شده در زمینه طبقه‌بندی خودکار صدای گریه نوزادان سهم قابل‌توجهی در این حوزه داشته‌اند. تحلیل و طبقه‌بندی صداهای گریه نوزاد با استفاده از روش‌های پردازش صدا و الگوریتم‌های یادگیری ماشین، اساس پژوهش‌های این حوزه را تشکیل می‌دهد.

این مقاله مروری، مطالعات مهم در زمینه طبقه‌بندی و تشخیص صدای گریه نوزاد را بررسی می‌کند. روش‌شناسی، مجموعه‌داده‌ها، روش‌های استخراج ویژگی و الگوریتم‌های طبقه‌بندی استفاده‌شده در این مطالعات به تفصیل مورد بحث قرار می‌گیرد.

مطالعات مختلفی در زمینه طبقه‌بندی گریه نوزاد، روش‌های گوناگونی را با استفاده از روش‌های پردازش صدا و الگوریتم‌های یادگیری ماشین توسعه داده‌اند. شارما شرایطی مانند گرسنگی، نیاز به آروغ زدن، درد شکم، ناراحتی، خستگی، تنهایی، احساس سرما یا گرما و ترس را در مجموعه داده Donate a Cry طبقه‌بندی کرد و با استفاده از ویژگی‌هایی مانند فرکانس میانگین، فرکانس میانه، آنتروپی طیفی و چولگی، با الگوریتم‌های k-میانگین، خوشه‌بندی سلسله‌مراتبی و مدل‌های ترکیبی گاوسی به دقت $27/81\%$ دست یافت.

مغفیرا با استفاده از مجموعه داده Dunstan Baby و الگوریتم CNN-RNN به موفقیت $97/94\%$ در طبقه‌بندی گرسنگی، ناراحتی، نیاز به دفع گاز و درد شکم دست یافت. به‌طور مشابه، فرانتی با CNN روی همان مجموعه داده به دقت 89% رسید. لیو [۶] با استفاده از ویژگی‌های LPC، LPCC، MFCC و BFCC بر روی صداهای ضبط‌شده در محیط NICU، با الگوریتم نزدیک‌ترین همسایه و شبکه‌های عصبی مصنوعی به موفقیت $4/76\%$ دست یافت. توران با کمک شبکه‌های کپسولی بر روی مجموعه داده CRIED به دقت $1/86\%$ رسید.

عثمانی با استفاده از پارامترهایی مانند طیف، تُن، نرخ عبور از صفر، ریشه میانگین مربعات، انرژی و ویژگی‌های آماری در مجموعه داده Dunstan Baby، با الگوریتم‌های SVM، درخت تصمیم کیسه‌ای (Bagging) (Decision Tree) و درختان تقویت‌شده (Boosted Trees) به طبقه‌بندی پرداخت. چانگ ویژگی‌های مبتنی بر طیف‌نگاشت را با استفاده از CNN برای طبقه‌بندی دسته‌های گرسنگی، درد و خواب بر روی مجموعه داده جمع‌آوری‌شده از بیمارستان دانشگاه ملی تایوان با نرخ دقت $5/78\%$ ارزیابی کرد. بانو با استفاده از ویژگی‌هایی مانند MFCC و انرژی کوتاه‌مدت بر روی داده‌های ضبط‌شده خود، با الگوریتم KNN به دقت 86% دست یافت. اورلاندی از ویژگی‌هایی مانند میانه، میانگین، انحراف معیار و مقادیر حداقل و حداکثر پارامترهای F0 و F123 برای تمایز نوزادان کامل‌رسیده و نارس استفاده کرد و با الگوریتم‌های رگرسیون لجستیک، پرسپترون چندلایه، SVM و RF به موفقیت 87% رسید. باگات‌پاتیل با استفاده از ویژگی‌های MFCC و LFCC بر روی داده‌های ضبط‌شده خود، با الگوریتم‌های خوشه‌بندی K-میانگین و KNN به دقت $58/91\%$ دست یافت. روزالس-پرز با استفاده از ویژگی‌های MFCC و LPC با الگوریتم مدل فازی بر روی مجموعه داده Baby Chillanto، حالات گرسنگی و درد را با دقت $96/97\%$ طبقه‌بندی کرد. یاماموتو با استفاده از ویژگی‌های FFT بر روی داده‌های ضبط‌شده خود شامل دسته‌های ناراحتی، گرسنگی و خواب، با الگوریتم نزدیک‌ترین همسایه به دقت $1/62\%$ رسید. در نهایت، بشیری و همکاران با استفاده از MFCC و الگوریتم شبکه عصبی مصنوعی (ANN) با مجموعه داده BabyChilanto به دقت $9/99\%$ دست یافتند.

مطالعات مختلفی در زمینه تشخیص گریه نوزاد، رویکردهای گوناگونی را برای غلبه بر چالش‌های این حوزه با استفاده از روش‌های پردازش صدا و الگوریتم‌های یادگیری ماشین توسعه داده‌اند. برای مثال، چانگ تشخیص گریه نوزاد را با استفاده از یک مجموعه داده خودضبط‌شده انجام داد. داده‌ها شامل صداهای زمینه مانند تلویزیون و گفتار بود و با استفاده از الگوریتم CNN و ویژگی‌های مبتنی بر طیف‌نگاشت، دقت $83/99\%$ حاصل شد. مانیکانتا با ضبط داده‌های گریه نوزاد همراه با صداهای کولر و پنکه در یک محیط خانگی، ویژگی‌های MFCC را استخراج کرد و با استفاده از الگوریتم‌های D-CNN، FFNN و SVM به نرخ دقت 86% دست یافت. دوی با الگوریتم KNN و ویژگی‌های LFCC بر روی یک مجموعه داده شامل صداهای گریه و غیر-گریه نوزاد که خود ضبط کرده بود، به دقت 90% رسید. گو از ویژگی‌های LPC بر روی مجموعه داده‌ای شامل صداهای زمینه مانند خنده و پارس سگ که خود ضبط کرده بود، استفاده کرد و با الگوریتم زمان‌پویایی پویا (Dynamic time warping) به نرخ موفقیت $1/97\%$ دست یافت. فرتی روی دو مجموعه داده مختلف کار کرد: اولی داده‌های واقعی ضبط‌شده در بخش مراقبت‌های ویژه نوزادان (NICU) یک بیمارستان؛ دومی مجموعه داده‌ای شامل صداهای مصنوعی مانند

گفتار و صداهای "بوق". از الگوریتم CNN با ویژگی‌های Log-Mel coefficients استفاده شد و نرخ دقت ۵۸٪/۸۶ در مجموعه داده واقعی و ۹۲٪/۹۲ در مجموعه داده مصنوعی به دست آمد. فایر روی مجموعه داده TUT Rare Sound Events 2017 کار کرد. این مجموعه داده شامل صداهایی مانند شکستن شیشه، شلیک گلوله و گریه نوزاد است. با استفاده از ویژگی‌های log-amplitude mel-spectrogram ، CRNN

به نرخ موفقیت ۸۵٪ برای تشخیص گریه نوزاد و ۸۷٪ برای تمام اهداف دست یافت. تورس روی مجموعه داده‌ای شامل صداهای زمینه، مانند گریه بزرگسالان و جاروبرقی، که از منابع آنلاین جمع‌آوری شده بود، کار کرد. ویژگی‌هایی مانند MFCC ، شمارنده صدادرایی صدا و تجمع نسبت هارمونیک با F0 متوالی از داده‌های صوتی استخراج شد. با الگوریتم‌های SVDD (توصیف‌گر بردار پشتیبان داده) و CNN ، نرخ AUC ۹۲٪ به دست آمد. لاونر روی مجموعه داده‌ای شامل صداهای زمینه مانند صحبت کردن و باز شدن در در یک محیط خانگی کار کرد. با استفاده از الگوریتم CNN و ویژگی‌هایی مانند MFCC ، گام زیروبمی (pitch) و فرمانت، دقت ۹۵٪ حاصل شد.

این مطالعه با هدف توسعه سیستمی است که بتواند نیازها یا ناراحتی‌های زمینه‌ای صدای گریه نوزادان را با تحلیل آنها به‌طور خودکار طبقه‌بندی کند. این سیستم با استفاده از تکنیک‌های پردازش صدا و الگوریتم‌های یادگیری ماشین، داده‌های معناداری استخراج کرده و این داده‌ها را طبقه‌بندی می‌کند و به والدین و مراقبان امکان می‌دهد تا به نیازهای نوزادان به‌طور دقیق و سریع پاسخ دهند. در این پژوهش از روش‌های پردازش صدا مانند ضرایب کپسترالی مل-فرکانسی (MFCC) استفاده خواهد شد. توسعه این سیستم با کاهش سطح استرس نوزادان از رشد سالم آنها حمایت می‌کند. علاوه بر این، با کاهش استرس والدین و مراقبان، به ایجاد رابطه‌ای سالم‌تر و شادتر کمک می‌کند. همچنین، این مطالعه به ادبیات دانشگاهی در زمینه پردازش صدا و یادگیری ماشین کمک کرده و به‌عنوان یک ابزار آموزشی و حمایتی عملی برای والدین راهنما خواهد بود.

مشارکت‌های اصلی مقاله به شرح زیر است:

این مطالعه با توسعه یک مدل یکپارچه مبتنی بر ANN برای طبقه‌بندی صداهای نوزاد، راه‌حلی مؤثرتر از رویکردهای موجود در این حوزه ارائه می‌دهد. مدل شبکه عصبی مصنوعی استفاده‌شده در مطالعه با بهینه‌سازی فراپارامتر با استفاده از الگوریتم بهینه‌سازی جستجوی شبکه‌ای بهبود یافته و نرخ دقت آن به‌طور قابل‌توجهی افزایش یافته است. بر اساس بهترین دانش ما، مدل پیشنهادی با بهترین نرخ دقت متوسط ۹۰٪، از کار موجود

که دقت ۹۳/۸۵٪ را بر روی داده‌های آزمون مجموعه داده Donate a Cry گزارش کرده بود، عملکرد بهتری دارد.

بقیه این مقاله به شرح زیر سازماندهی شده است. مواد و روش‌ها در بخش ۲ ارائه شده است. بخش ۳ مطالعات تجربی شامل راه‌اندازی آزمایشی و نتایج را توصیف می‌کند. در نهایت، بخش ۴ نتیجه‌گیری و کارهای آینده را خلاصه می‌کند.

۲. مواد و روش‌ها

۲.۱. راه‌اندازی آزمایشی

راه‌اندازی سخت‌افزاری و نرم‌افزاری در زیربخش‌های زیر به تفصیل توضیح داده شده است.

۲.۱.۱. راه‌اندازی سخت‌افزاری

آموزش یادگیری عمیق بر روی رایانه‌ای با مشخصات زیر انجام شد CPU: (اینتل زئون ۳۰/۳ گیگاهرتز)، ۱۲۸ گیگابایت RAM، و GPU انویدیا با CUDA Toolkit نسخه ۲/۱۱ (cu112).

۲.۱.۲. نصب نرم‌افزار

برای ایجاد مدل‌های شبکه عصبی مصنوعی جهت طبقه‌بندی صداها، از برنامه‌نویسی پایتون (نسخه ۳/۲۰/۸) استفاده شد. ساختار منعطف پایتون و پشتیبانی گسترده از کتابخانه‌ها، هوش مصنوعی و پردازش داده را تسهیل کرد. از کتابخانه‌های TensorFlow (نسخه ۲/۲/۱۳) و Keras (نسخه ۲/۲/۱۳) برای طبقه‌بندی صداها، ایجاد مدل‌ها و فرآیندهای آموزش استفاده شد. در حالی که TensorFlow با زیرساخت محاسباتی با کارایی بالا، فرآیند آموزش مدل را تسریع کرد، Keras با رابط کاربرپسند خود، فرآیندهای طراحی مدل، بهینه‌سازی فراپارامتر و ارزیابی را تسهیل کرد. علاوه بر این، از کتابخانه Librosa (نسخه ۲/۹/۰) برای پردازش و تحلیل داده‌های صوتی استفاده شد. با کمک Librosa، بارگذاری و نرمال‌سازی فایل‌های صوتی و استخراج ویژگی‌های مهم صوتی مانند طیف‌نگاشت مل و MFCC فراهم شد. نسخه‌های کتابخانه‌ها و زبان برنامه‌نویسی استفاده‌شده در جدول ۱ نشان داده شده است.

جدول ۱. نسخه‌های نرم‌افزاری استفاده‌شده در مطالعه.

طبقه	تعداد رکورد
درد شکم	۱۶
آروغ زدن	۸
ناراحتی	۲۷
گرسنه	۳۸۲
خسته	۲۴
مجموع	۴۵۷

۲.۲.۲. تقسیم‌بندی داده

مرحله تقسیم‌بندی برای درک ساختار زیربنایی مجموعه داده حیاتی است. قبل از رفتن به مرحله پیش‌پردازش، داده‌ها به سه زیرمجموعه تقسیم شدند: مجموعه آموزش ۷۵٪، مجموعه اعتبارسنجی ۱۰٪ و مجموعه آزمون ۱۵٪. تعیین این زیرمجموعه‌ها برای ارائه ارزیابی بی‌طرفانه از عملکرد مدل و انجام مقایسه منصفانه با مطالعات موجود در ادبیات انجام شد.

فایل‌های صوتی قبل از طبقه‌بندی افزایش داده شدند. در طول فرآیند افزایش داده، فایل‌های صوتی تازه ایجاد شده با افزودن مخفف `aug` به نام فایل‌های خود ثبت شدند. هنگام جدا کردن فایل‌های صوتی آموزش و آزمون، فایل‌های صوتی مختلف در هر طبقه بر اساس نام فایل‌هایشان جدا شدند.

۲.۳. پیش‌پردازش داده

افزایش داده و استخراج ویژگی بر روی مجموعه داده برای پیش‌پردازش اعمال شد و در زیربخش‌های بعدی به تفصیل ارائه شده است.

۲.۳.۱. افزایش داده (DA)

روش‌های افزایش داده صوتی از تکنیک‌های مختلفی برای افزایش توانایی تعمیم‌پذیری مدل و افزودن تنوع به مجموعه داده استفاده می‌کنند. تکنیک‌های افزایش داده زیر با استفاده از ابزار Librosa پیاده‌سازی شدند:

۱. **جابه‌جایی زمانی (Time Shift)** جابه‌جایی سیگنال صوتی در زمان به میزان مشخص (مثبت یا منفی) مدل را نسبت به موقعیت صدا غیرحساس می‌کند. این تکنیک زمانی استفاده می‌شود که اطلاعات وابسته به زمان‌بندی صدا نباید برای مدل مهم باشد و مدل را در برابر نمونه‌های صوتی با زمان‌بندی‌های مختلف مقاوم می‌سازد.

۲. **کشش زمانی (Time Stretch)** تغییر طول صدا بدون تغییر سرعت آن، یعنی تند یا کند کردن آن، به مدل امکان می‌دهد در برابر سرعت‌های مختلف صدا مقاوم باشد. این به مدل کمک می‌کند تا نسبت به تمپوهای مختلف صدا انعطاف‌پذیر باشد و با وجود تغییرات سرعت، پیش‌بینی‌های دقیقی انجام دهد.

۳. **تغییر گام زیروبمی (Pitch Shift)** تغییر گام زیروبمی صدا، یعنی جابه‌جایی فرکانسی، مدل را در برابر تُن‌های مختلف مقاوم می‌کند. تغییر گام زیروبمی به مدل‌هایی که به‌ویژه نسبت به تغییرات گام زیروبمی حساس نیستند، امکان می‌دهد تا در طیف وسیعی از تُن‌ها تعمیم‌پذیرتر باشند.

۴. **افزودن نویز سفید (Add White Noise)** افزودن سطح پایینی از نویز سفید تصادفی به سیگنال صوتی به مدل امکان می‌دهد در محیط‌های نویزی عملکرد بهتری داشته باشد. این تکنیک به مدل کمک می‌کند تا بهتر با محیط‌های دنیای واقعی، به‌جز زمانی که صدا تمیز است، سازگار شود.

۵. **تکه‌تکه کردن (Slice)** تولید نمونه‌های صوتی کوتاه‌تر با برداشتن تصادفی یک بخش از یک فایل صوتی طولانی، به مدل امکان می‌دهد بر روی بخش‌های خاص صوتی تمرکز کند. این به مدل اجازه می‌دهد تا اطلاعات موجود در فایل‌های صوتی طولانی را به‌طور مؤثرتری یاد بگیرد و بر جزئیات مهم در بخش‌های کوتاه خاص تمرکز کند.

پارامترهای روش‌های استفاده‌شده در جدول ۳ نشان داده شده است.

جدول ۳. پارامترهای افزایش داده برای Donate a Cry.

روش	تکنیک	پارامتر	مقدار	توضیحات
جابه‌جایی زمانی	جابه‌جایی	نمونه‌ها	۵۰۰ - تا ۵۰۰	پیمایش تصادفی

ککش زمانی	تغییر سرعت	نسبت	۸/۰ تا ۲/۱	تغییر سرعت تصادفی
تغییر گام زیروبی	تغییر گام زیروبی	نیم پرده ها	+۴	افزایش زیروبی
افزودن نویز	نویز گاوسی	میانگین	۰	نویز سفید
		واریانس	۰۰۰۰۲۵/۰	نویز سطح پایین
		توان	۰۰۵/۰	۵٪ از دامنه سیگنال
تکه تکه کردن	قطعه بندی	مدت زمان	۱ ثانیه	برش یک بخش تصادفی

۲.۳.۲. تغییر اندازه داده

یکسان سازی طول فایل های صوتی با طول های متفاوت، تضمین می کند که مدل هر نمونه صوتی را با اندازه یکسان دریافت کند و فرآیند آموزش سازگارتری ایجاد می کند. وقتی فایل های صوتی طول های متفاوتی دارند، مدل اغلب نیاز دارد تا فایل های صوتی را به یک طول مشخص تنظیم کند تا هر نمونه را به درستی پردازش کند. این کار را می توان با برش انتهای فایل صوتی یا پر کردن بخش مفقود انجام داد.

این روش در مطالعه، به ویژه زمانی که طول فایل های صوتی متفاوت بود، استفاده شد. اگر طول فایل صوتی کوتاه تر از اندازه مشخص شده باشد، فایل صوتی با افزودن صفر در انتها (پر کردن) به طول مشخص شده تکمیل می شود. اگر طول فایل صوتی بلندتر از اندازه مشخص شده باشد، بخش اضافی فایل صوتی بریده می شود (برش). این به مدل کمک می کند تا با دریافت هر نمونه صوتی به همان اندازه، فرآیند آموزشی سازگاری ارائه دهد.

برش (Trimming): کوتاه کردن یک فایل صوتی به طول مشخص است. در فایل های صوتی طولانی، بخش هایی که از حداکثر طول مشخص شده تجاوز می کنند، بریده می شوند. این کار معمولاً بر این فرض انجام می شود که بخش مهم صدا در ابتدا قرار دارد.

پر کردن (Padding): فرآیند افزودن صفر یا یک مقدار ثابت به فایل های صوتی کوتاه تا زمانی که به طول مشخصی برسند. این به ویژه زمانی مفید است که مجموعه داده شامل فایل های صوتی بسیار کوتاه باشد. پر کردن را می توان به انتهای صدا اضافه کرد یا در یک بازه زمانی مشخص توزیع کرد.

حداقل، حداکثر و میانگین مدت زمان رکوردها در مجموعه داده بر اساس طبقات در جدول ۴ نشان داده شده است.

جدول ۴. مدت زمان برای Donate a Cry.


طبقه	حداقل مدت (ثانیه)	حداکثر مدت (ثانیه)	میانگین مدت (ثانیه)
درد شکم	۷۰/۵	۱۹/۸	۹۳/۶
آروغ زدن	۴۰/۶	۹۴/۷	۹۴/۶
ناراحتی	۸۷/۵	۲۸/۸	۹۵/۶
گرسنه	۵۲/۶	۰۶/۷	۹۱/۶
خسته	۷۷/۵	۵۴/۸	۸۷/۶

شبکه‌های عصبی مصنوعی (ANN) معمولاً با بردارهای ورودی با طول ثابت کار می‌کنند. با این حال، در داده‌هایی با مدت زمان متغیر، مانند داده‌های صوتی، طول هر رکورد ممکن است متفاوت باشد. این امر می‌تواند برای ANN در دریافت بردارهای ورودی مشکل‌ساز باشد، زیرا شبکه نیاز به کار با یک بردار با طول ثابت دارد که انتظار دارد. بنابراین، روش‌های پر کردن و برش برای یکسان‌سازی طول فایل‌های صوتی اعمال می‌شوند.


۲.۳.۳. استخراج ویژگی

یک مرور جامع از ادبیات برای بهبود فرآیند استخراج ویژگی انجام شد. مطالعات مهم توسط Chunyan Ji به تفصیل بررسی شد و انتخاب ویژگی با توجه به این مطالعات انجام گرفت. از میان ویژگی‌های انتخاب‌شده از حوزه کپسترال، ضرایب کپسترالی مل-فرکانسی (MFCC) قرار دارند. ویژگی‌های نرخ عبور از صفر (ZCR) و ریشه میانگین مربعات (RMS) از حوزه زمانی نیز مورد بررسی قرار گرفتند، اما تنها از ویژگی MFCC در این مطالعه استفاده شد.

نمونه‌هایی از تصاویر MFCC هر طبقه در شکل ۱ نشان داده شده است.



شکل ۱ - نمونه طیف‌نگاشت مل برای هر طبقه



شکل ۲ - بلوک‌دیگرام طیف‌نگاری مل

۱. **پیش‌تأکید: (Pre-Emphasis)** سیگنال گفتار اولیه $x(n)$ از یک فیلتر بالاگذر عبور داده می‌شود تا اجزای فرکانس بالاتر تقویت شوند:

$$y(n) = x(n) - a \cdot x(n - 1)$$

در اینجا، $y(n)$ سیگنال فیلترشده را نشان می‌دهد و ضریب a معمولاً بین ۰/۹ و ۰/۱ قرار دارد. این مرحله فرکانس‌های بالاتر را برجسته می‌کند و انرژی آنها را برای استخراج ویژگی بهتر افزایش می‌دهد.

۲. **قطعه‌بندی فریم (Frame Blocking):** سیگنال گفتار معمولاً به فریم‌های هم‌پوشان تقسیم می‌شود که هر کدام بین ۲۰ تا ۳۰ میلی‌ثانیه طول دارند. فریم‌ها مقدار مشخصی هم‌پوشانی دارند و طول فریم معمولاً بیشتر از این هم‌پوشانی است. مقادیر رایج استفاده‌شده برای طول فریم و هم‌پوشانی به ترتیب ۲۵۶ و ۱۰۰ هستند.

۳. **پنجره‌گذاری (Windowing):** پنجره‌گذاری برای کاهش ناپیوستگی‌های سیگنال در لبه‌های فریم اعمال می‌شود. از یک تابع پنجره هموار، مانند پنجره همینگ، استفاده می‌شود که در انتهای خود به صفر می‌رسد. این رویکرد پیوستگی سیگنال را بین فریم‌ها حفظ می‌کند. پنجره همینگ به صورت فرمول (۲) تعریف می‌شود:

$$Y(n) = X(n) \cdot W(n)$$

در اینجا، $W(n)$ تابع پنجره است.

۴. **تبدیل فوریه سریع (FFT):** FFT سیگنال حوزه زمان را به حوزه فرکانس تبدیل می‌کند و استخراج ویژگی را با حفظ تمام اطلاعات ضروری تسهیل می‌کند. طیف دامنه با استفاده از فیلترهای میان‌گذر مثلثی هموار می‌شود تا پردازش گفتار ساده‌تر شود.

۵. **تبدیل کسینوسی گسسته (DCT):** DCT بر روی خروجی‌های فیلترهای میان‌گذر برای محاسبه ضرایب کپسترالی مل-فرکانسی (MFCC) اعمال می‌شود. تبدیل از حوزه فرکانس به حوزه زمان با فرمول (۳) داده می‌شود:

$$C(n) = \sum E_k \cdot \cos\left(n \cdot (k - 0.5) \cdot \frac{\pi}{40}\right)$$

در اینجا، n از ۰ تا N متغیر است، N تعداد فیلترهای میان‌گذر مثلثی را نشان می‌دهد و L تعداد ضرایب کپسترالی مقیاس مل است.

مقدار k شاخص فیلترهای میان‌گذر است و معمولاً تعداد مؤلفه‌های فرکانسی را نشان می‌دهد. این مقدار ترتیب فیلترهای میان‌گذر استفاده‌شده را نشان می‌دهد. این ضرایب به طور گسترده در وظایف تشخیص گفتار استفاده می‌شوند.

در این مطالعه، از پارامترهای خاصی برای استخراج ویژگی‌های ضریب کپسترالی مل-فرکانسی (MFCC) از سیگنال‌های صوتی استفاده شد. فرکانس نمونه‌برداری (نرخ نمونه) ۱۶۰۰۰ هرتز انتخاب شد. این انتخاب یک استاندارد رایج، به‌ویژه در کاربردهای پردازش گفتار و صوتی عمومی است و نمایش با وضوح کافی از صدا را

فراهم می‌کند.

تعداد ضرایب MFCC برابر با ۱۳ تعیین شد. به‌طور کلی، چند ضریب اول MFCC ویژگی‌های طیفی پایه صدا را نشان می‌دهند، در حالی که ضرایب بالاتر جزئیات دقیق را ثبت می‌کنند. استفاده از ۱۳ ضریب، انتخابی متعادل از نظر جلوگیری از اتلاف اطلاعات و حفظ بار پردازشی در سطحی معقول است.

در محاسبه MFCC، به جای ضرایبی که در طول زمان تغییر می‌کنند، ترجیح داده شده است که مقادیر میانگین گرفته شوند. به این ترتیب، تأثیر نوسانات کوتاه‌مدت در سیگنال صوتی کاهش می‌یابد و یک بردار ویژگی پایدارتر به‌دست می‌آید. علاوه بر این، با استفاده از بانک‌های فیلتر فرکانس مل و تبدیل کسینوسی گسسته (DCT)، توزیع فرکانسی درک‌شده توسط گوش انسان بهتر مدل‌سازی می‌شود و ویژگی‌های متمایزکننده صدا به‌طور مؤثرتری استخراج می‌گردند. انتخاب این پارامترها به منظور به حداقل رساندن اتلاف اطلاعات در حین توصیف سیگنال‌های صوتی و افزایش عملکرد طبقه‌بندی انجام شده است. قبل از تغذیه MFCC ها به شبکه، ویژگی‌ها بردارسازی می‌شوند.

کتابخانه‌های محبوب پایتون مانند Scipy، Numpy و Pandas نقش محوری در پیاده‌سازی مراحل استخراج ویژگی و نرمال‌سازی ایفا کردند و فرآیندی کارآمد و روان را ممکن ساختند.

۲.۴. روش‌های شبکه عصبی مصنوعی

شبکه‌های عصبی مصنوعی (ANN) مدل‌های محاسباتی هستند که از معماری و عملکرد شبکه‌های عصبی در مغز انسان الهام گرفته‌اند. این مدل‌ها فرآیندهای عصبی زیستی را ساده‌سازی می‌کنند تا سیستم‌های به‌هم‌پیوسته‌ای ایجاد کنند که قادر به انجام وظایف گوناگون هستند. ANN ها که اغلب در زمینه‌های دانشگاهی و مهندسی به‌عنوان شبکه‌های عصبی یا شبکه‌های عصبی مستقیم شناخته می‌شوند، از گره‌های متعددی (نورون‌ها) تشکیل شده‌اند که برای پردازش اطلاعات با هم کار می‌کنند.

هر گره در شبکه یک تابع خروجی خاص، که معمولاً به‌عنوان تابع فعال‌سازی شناخته می‌شود، انجام می‌دهد. ارتباطات بین گره‌ها با وزن‌هایی همراه هستند که قدرت سیگنال ارسال شده از طریق این پیوندها را تعیین می‌کنند. این وزن‌ها مشابه حافظه شبکه عصبی هستند و نقش مهمی در فرآیند یادگیری آن ایفا می‌کنند. خروجی کلی شبکه به ساختار ارتباطات آن، مقادیر وزن‌های اختصاص داده‌شده و توابع فعال‌سازی انتخاب‌شده بستگی دارد.

ANNها می‌توانند الگوریتم‌ها یا توابع پیچیده را تقریب بزنند که اغلب نشان‌دهنده عملیات منطقی یا راهبردی هستند.

معماری شبکه‌های عصبی مصنوعی (ANN) معمولاً در سه لایه اصلی سازماندهی می‌شود: لایه ورودی، لایه(های) پنهان و لایه خروجی. لایه ورودی به‌عنوان رابط بین شبکه و محیط خارجی عمل می‌کند و سیگنال‌ها و داده‌ها را برای پردازش دریافت می‌کند. لایه(های) پنهان که بین لایه‌های ورودی و خروجی قرار دارند، پردازش میانی داده‌های دریافتی را انجام می‌دهند. این لایه‌ها به‌طور مستقیم از خارج قابل مشاهده نیستند، اما نقش مهمی در استخراج ویژگی‌ها و یادگیری الگوها ایفا می‌کنند. در نهایت، لایه خروجی نتایج شبکه را تولید می‌کند و اطلاعات پردازش‌شده را به کاربر یا یک سیستم خارجی تحویل می‌دهد. با تغییر اتصالات بین گره‌ها، تنظیم وزن‌ها و انتخاب

توابع فعال سازی مناسب، ANN ها را می توان برای انجام طیف گسترده ای از وظایف، از محاسبات پایه گرفته تا حل مسائل پیچیده و انتزاعی، سفارشی سازی کرد.

این مطالعه بر توسعه مدلی مبتنی بر شبکه های عصبی مصنوعی (ANN) متمرکز است. مرحله اول مدل با یک معماری ANN پایه شروع می شود. بلوک های سازنده این مدل پایه به شرح زیر است:

- **لایه ورودی:** لایه ای که داده ها به مدل معرفی می شوند.
- **پنج لایه پنهان:** لایه هایی که به مدل امکان می دهند روابط پیچیده تر را یاد بگیرد. این لایه ها شامل مؤلفه های زیر هستند:
 - **تبدیل خطی:** پردازش داده ها به صورت خطی.

- **نرمال سازی:** نرمال سازی برای پردازش داده ها به صورت استاندارد انجام می شود.
- **فعال سازی ReLU:** تابع فعال سازی ReLU (واحد خطی تصحیح شده) تابعی است که ورودی های منفی را برابر با صفر و ورودی های مثبت را به صورت خودشان قرار می دهد:

$$f(x) = \max(0, x)$$

این تابع به دلیل سادگی و ساختار خطی تکه ای، به طور مکرر در مدل های یادگیری عمیق استفاده می شود.

- **لایه Dropout:** برخی از نورون ها به طور تصادفی خاموش می شوند تا از بیش برآزش (overfitting) مدل جلوگیری شود.

- **لایه خروجی:** این آخرین لایه ای است که مدل نتایج را تولید می کند و در اینجا از تابع فعال سازی LogSoftmax استفاده می شود. این تابع با گرفتن لگاریتم خروجی ها، احتمالات هر طبقه را نرمال سازی می کند.


$$\text{LogSoftmax}(z)_i = \log\left(\frac{e^{z_i}}{\sum_{j=1}^K e^{z_j}}\right)$$

در اینجا:

- بردار $\mathbf{z}$ خروجی است که نمره طبقه‌بندی مدل است؛
- i نشان‌دهنده هر یک از این نمرات است؛
- K نشان‌دهنده تعداد کل طبقات است.

۲.۵. روش پیشنهادی

هدف اصلی این مطالعه، توسعه یک سیستم طبقه‌بندی یکپارچه مؤثر برای تشخیص انواع مختلف صداهای گریه نوزاد است. روش پیشنهادی شامل چهار مرحله اصلی است: افزایش داده، استخراج ویژگی، تنظیم فرآیند و آموزش مدل. معماری کلی روش پیشنهادی در شکل ۳ نشان داده شده است.



شکل ۳- معماری روش پیشنهادی

مرحله ۱: افزایش داده. به منظور بهبود توانایی تعمیم‌پذیری مدل و جلوگیری از بیش‌برازش، تکنیک‌های افزایش داده بر روی سیگنال‌های صوتی خام اعمال می‌شوند. افزایش داده به‌ویژه در کاربردهای یادگیری عمیق که مقدار داده‌های آموزشی موجود محدود است، اهمیت دارد. در این مرحله، افزایش داده بر روی داده‌های صوتی با استفاده از روش‌های جابه‌جایی زمانی، کشش زمانی، تغییر گام زیروبمی، افزودن نویز سفید و تکه‌تکه‌کردن اعمال می‌شود. افزایش داده برای کل مجموعه انجام شد. هنگام تقسیم‌بندی، دقت شد که داده‌های واقعی و


افزایش یافته در هر دو مجموعه آموزش و آزمون وجود نداشته باشند. جزئیات بیشتر در مورد تکنیک‌های افزایش داده در بخش ۱/۳/۲ ارائه شده است.

مرحله ۲: استخراج ویژگی. ضرایب کپسترالی مل-فرکانسی (MFCC) به‌طور گسترده در پردازش گفتار و صدا استفاده می‌شوند زیرا ویژگی‌های طیفی یک سیگنال صوتی را به‌گونه‌ای که شبیه به ادراک شنوایی انسان است، به‌طور مؤثری ثبت می‌کنند. در این مرحله، MFCCها از نمونه‌های صوتی افزایش یافته استخراج می‌شوند. ویژگی‌های MFCC استخراج شده به‌عنوان ورودی مدل طبقه‌بندی عمل می‌کنند. جزئیات بیشتر در مورد استخراج ویژگی در بخش ۳/۳/۲ یافت می‌شود.

مرحله ۳: تنظیم فرآپارامتر برای بهینه‌سازی عملکرد طبقه‌بندی شبکه عصبی مصنوعی (ANN)، تنظیم فرآپارامتر با استفاده از الگوریتم جستجوی شبکه‌ای (GS) انجام می‌شود. جستجوی شبکه‌ای به‌طور سیستماتیک

یک مجموعه از پیش تعریف شده از مقادیر فرارامتر را برای یافتن ترکیبی که بهترین عملکرد را ارائه می دهد، کاوش می کند. پارامترهای بهینه سازی شده در این مطالعه شامل موارد زیر است:

- **تعداد لایه های پنهان و نورون ها:** معماری ANN برای ایجاد تعادل بین پیچیدگی مدل و کارایی محاسباتی تنظیم می شود.
- **نرخ یادگیری:** اندازه گام برای به روز رسانی وزن ها برای اطمینان از همگرایی کارآمد بهینه می شود.
- **اندازه دسته (Batch Size):** تعداد نمونه های آموزشی استفاده شده در هر تکرار برای بهینه سازی پایداری آموزش تنظیم می شود.
- **توابع فعال سازی:** توابع فعال سازی مختلف (مانند ReLU، سیگموئید، تانه (از نظر تأثیرشان بر عملکرد مدل ارزیابی می شوند).
- **انتخاب بهینه ساز:** علاوه بر تنظیم فرارامتر، خود الگوریتم بهینه سازی نیز بهینه می شود. سه بهینه ساز مختلف Adam، RMSProp و SGD برای تعیین مناسب ترین گزینه برای مدل ارزیابی می شوند. ساختار بهینه شده ANN در شکل ۴ نشان داده شده است.



شکل ۴ - تنظیم ساختار یافته برای روش پیشنهادی

مرحله ۴: آموزش و ارزیابی مدل مرحله نهایی شامل آموزش و ارزیابی مدل ANN با استفاده از مجموعه داده Donate a Cry است. مجموعه داده به زیرمجموعه های آموزش و آزمون تقسیم می شود و اطمینان حاصل

می‌شود که مدل بر روی مجموعه متنوعی از صداهای گریه آموزش دیده و بر روی نمونه‌های دیده‌نشده ارزیابی می‌شود.

فرآیند آموزش شامل موارد زیر است:

- **مقداردهی اولیه وزن‌ها:** وزن‌های مدل با استفاده از یک استراتژی مناسب برای جلوگیری از گرادیان‌های محوشونده یا منفجرشونده مقداردهی اولیه می‌شوند.
 - **پس‌انتشار و بهینه‌سازی:** تابع هزینه با استفاده از بهینه‌ساز انتخاب‌شده به حداقل می‌رسد و وزن‌های مدل بر اساس آن به‌روزرسانی می‌شوند.
 - **ارزیابی عملکرد:** مدل آموزش‌دیده بر روی صداهای گریه دیده‌نشده آزمایش می‌شود و دقت طبقه‌بندی، صحت، یادآوری و نمره F1 آن برای ارزیابی اثربخشی محاسبه می‌شوند.
- از طریق این مراحل سیستماتیک، روش پیشنهادی با بهره‌گیری از افزایش داده، استخراج ویژگی، تنظیم فرآپارامتر و آموزش بهینه‌شده مدل، طبقه‌بندی مقاوم صداهای گریه نوزاد را تضمین می‌کند.

۳. نتایج تجربی

این مقاله از VGG16 (یک مدل CNN از پیش‌آموزش‌دیده شامل ۱۶ لایه که به‌طور مکرر در وظایف طبقه‌بندی تصویر استفاده می‌شود و نقطه عطف مهمی در حوزه یادگیری عمیق است)، KNN، CNN، روش‌های مبتنی بر جنگل تصادفی (M1، M2، M3، M4، M5 و M6) و روش پیشنهادی مبتنی بر ANN برای طبقه‌بندی صداهای نوزاد استفاده کرد. این روش‌ها برای تحلیل داده‌های صوتی به منظور طبقه‌بندی صداهای نوزاد به کار گرفته شدند. هدف استفاده از این روش‌ها با تکرار مطالعات موجود در ادبیات با نرخ‌های دقت بالا است. در مرحله آزمایش مدل‌ها، مجموعه داده Donate a Cry برای طبقه‌بندی صداهای

نوزاد آزمایش و مقایسه شد. در شبیه‌سازی‌ها، مجموعه داده به سه بخش تقسیم شد، ۷۵٪ برای آموزش، ۱۰٪ برای اعتبارسنجی و ۱۵٪ برای آزمون

در روش پیشنهادی، بهینه‌سازی فرآپارامتر با استفاده از الگوریتم جستجوی شبکه‌ای (GS) برای تنظیم پارامترهای ANN انجام شد. فرآپارامترهای نزدیک به بهینه انتخاب‌شده توسط GS در جدول ۵ نشان داده شده است.

در حین استفاده از الگوریتم بهینه‌سازی جستجوی شبکه‌ای، نه تنها بهینه‌سازی فرآپارامتر، بلکه خود الگوریتم بهینه‌سازی نیز بهینه می‌شود. در این فرآیند، سه گزینه بهینه‌ساز مختلف به الگوریتم جستجوی شبکه‌ای ارائه می‌شود: Adam، RMSProp و SGD. به این ترتیب، با تعیین مناسب‌ترین ترکیب بهینه‌ساز و فرآپارامتر، عملکرد مدل افزایش می‌یابد.

جدول ۵. مقادیر فرآپارامتر ANN انتخاب‌شده توسط GS

پارامتر	مقدار
اندازه دسته	۳۲
دوره (Epoch)	۱۰۰
بهینه‌ساز	Adam
فعال‌سازی	ReLU
لایه‌های پنهان	۵
Dropout	۵/۰

در جدول ۶، نتایج مقایسه عملکرد مدل‌های مختلف برای طبقه‌بندی صداهای نوزاد ارائه شده است. مدل‌ها با روش‌هایی مانند (DA افزایش داده)، MFCC (ضرایب کپسترالی مل-فرکانسی) و SF (صافی طیفی) به‌عنوان ویژگی‌های صوتی پشتیبانی شدند. مقادیر صحت، یادآوری و نمره F1 به‌عنوان معیارهای عملکرد بررسی شدند.

جدول ۶. مقایسه عملکرد روش پیشنهادی در مقابل سایر مدل‌های تولیدشده

روش	تکنیک‌ها	معیار	درد شکم	آروغ زدن	ناراحتی	گرسنگی	خستگی
M1	RF + DA + MFCC	صحت	۰.۰٪/۰.۰	۰.۰٪/۰.۰	۰.۰٪/۱۸	۰.۰٪/۸۳	۰.۰٪/۰.۰
		یادآوری	۰.۰٪/۰.۰	۰.۰٪/۰.۰	۰.۰٪/۴	۰.۰٪/۸۸	۰.۰٪/۰.۰
		نمره F1	۰.۰٪/۰.۰	۰.۰٪/۰.۰	۰.۰٪/۸	۰.۰٪/۸۵	۰.۰٪/۰.۰
M2	One-vs-All + DA + SF	صحت	۰.۰٪/۰.۰	۰.۰٪/۰.۰	۰.۰٪/۰.۰	۰.۰٪/۸۳	۰.۰٪/۰.۰
		یادآوری	۰.۰٪/۰.۰	۰.۰٪/۰.۰	۰.۰٪/۰.۰	۰.۰٪/۱۰۰	۰.۰٪/۰.۰
		نمره F1	۰.۰٪/۰.۰	۰.۰٪/۰.۰	۰.۰٪/۰.۰	۰.۰٪/۹۱	۰.۰٪/۰.۰
M3	KNN + DA + SF	صحت	۰.۰٪/۰.۰	۰.۰٪/۰.۰	۰.۰٪/۵۰	۰.۰٪/۸۵	۰.۰٪/۰.۰
		یادآوری	۰.۰٪/۰.۰	۰.۰٪/۰.۰	۰.۰٪/۴	۰.۰٪/۹۹	۰.۰٪/۰.۰
		نمره F1	۰.۰٪/۰.۰	۰.۰٪/۰.۰	۰.۰٪/۸	۰.۰٪/۹۱	۰.۰٪/۰.۰
M4	CNN + MFCC	صحت	۰.۰٪/۰.۰	۰.۰٪/۰.۰	۰.۰٪/۰.۰	۰.۰٪/۷۷	۰.۰٪/۰.۰
		یادآوری	۰.۰٪/۰.۰	۰.۰٪/۰.۰	۰.۰٪/۰.۰	۰.۰٪/۱۰۰	۰.۰٪/۰.۰
		نمره F1	۰.۰٪/۰.۰	۰.۰٪/۰.۰	۰.۰٪/۰.۰	۰.۰٪/۸۷	۰.۰٪/۰.۰
M5	VGG16 + MFCC	صحت	۰.۰٪/۰.۰	۰.۰٪/۰.۰	۰.۰٪/۰.۰	۰.۰٪/۸۷	۰.۰٪/۰.۰
		یادآوری	۰.۰٪/۰.۰	۰.۰٪/۰.۰	۰.۰٪/۰.۰	۰.۰٪/۹۷	۰.۰٪/۰.۰
		نمره F1	۰.۰٪/۰.۰	۰.۰٪/۰.۰	۰.۰٪/۰.۰	۰.۰٪/۹۲	۰.۰٪/۰.۰
M6	Alexnet + Split + MFCC	صحت	۰.۰٪/۰.۰	۰.۰٪/۰.۰	۰.۰٪/۰.۰	۰.۰٪/۸۷	۰.۰٪/۰.۰
		یادآوری	۰.۰٪/۰.۰	۰.۰٪/۰.۰	۰.۰٪/۰.۰	۰.۰٪/۱۰۰	۰.۰٪/۰.۰
		نمره F1	۰.۰٪/۰.۰	۰.۰٪/۰.۰	۰.۰٪/۰.۰	۰.۰٪/۹۳	۰.۰٪/۰.۰
پیشنهادی	ANN + GS + DA + MFCC	صحت	۰.۰٪/۹۴	۰.۰٪/۱۰۰	۰.۰٪/۹۶	۰.۰٪/۹۰	۰.۰٪/۷۹
		یادآوری	۰.۰٪/۹۷	۰.۰٪/۱۰۰	۰.۰٪/۹۱	۰.۰٪/۸۱	۰.۰٪/۹۲
		نمره F1	۰.۰٪/۹۵	۰.۰٪/۱۰۰	۰.۰٪/۹۳	۰.۰٪/۸۵	۰.۰٪/۸۵

عملکرد ضعیف سایر روش‌ها در طبقات اقلیت، احتمالاً به دلیل عدم تعادل طبقاتی در مجموعه داده است. مدل‌های سنتی مانند جنگل تصادفی (RF)، k-نزدیک‌ترین همسایه (KNN) و One-vs-All تمایل دارند به طبقات اکثریت تمایل نشان دهند، زیرا به ویژگی‌های دست‌ساز متکی هستند که ممکن است تفاوت‌های ظریف بین دسته‌های گریه را به اندازه کافی ثبت نکنند. وقتی مجموعه داده نامتوازن است، این مدل‌ها اغلب یاد می‌گیرند که برای طبقه مسلط بهینه‌سازی کنند که منجر به کاهش قابل توجه عملکرد برای طبقات کمتر نمایش داده شده می‌شود.

علاوه بر این، روش‌های یادگیری ماشین سنتی با ماهیت پیچیده و با ابعاد بالای صداهای گریه نوزاد که تغییرات پیچیده‌ای در فرکانس، دامنه و الگوهای زمانی دارند، دچار مشکل می‌شوند. این مدل‌ها معمولاً به ویژگی‌های آماری از پیش تعریف شده، مانند MFCC یا ویژگی‌های طیفی متکی هستند که ممکن است برای تشخیص مؤثر طبقات اقلیت به اندازه کافی رصا نباشند.

از سوی دیگر، مدل‌های یادگیری عمیق، به ویژه شبکه‌های عصبی مصنوعی (ANN)، مزیت یادگیری بازنمایی‌های سلسله‌مراتبی و انتزاعی ویژگی را مستقیماً از داده‌ها دارند. با بهره‌گیری از تکنیک‌های بهینه‌سازی پیشرفته و معماری‌های عصبی، این مدل‌ها قادر به ثبت تفاوت‌های ظریف بین انواع گریه هستند، حتی در مواردی که طبقات خاصی نمونه‌های آموزشی کمتری دارند.

علاوه بر این، روش پیشنهادی ما از جستجوی شبکه‌ای (GS) برای تنظیم فرآپارامتر، افزایش داده (DA) برای کاهش عدم تعادل طبقاتی و استخراج ویژگی مبتنی بر MFCC استفاده می‌کند که همگی به عملکرد برتر آن کمک می‌کنند. توانایی ANN در تعمیم‌پذیری خوب در انواع مختلف گریه، با وجود عدم تعادل داده، اثربخشی آن را در این وظیفه طبقه‌بندی بیشتر برجسته می‌کند. بهبودهای آینده می‌تواند شامل استفاده از تکنیک‌های افزایش داده پیشرفته‌تر یا توابع هزینه تطبیقی برای افزایش بیشتر عملکرد در تمام طبقات باشد.

هنگام بررسی نتایج، بالاترین مقادیر دقت (۹۰٪) و نمره F1 (۹۰٪) (با روش پیشنهادی مبتنی بر شبکه عصبی مصنوعی (ANN) با ساختار تنظیم شده به دست آمد. روش پیشنهادی از نظر دقت و نمره F1 بهترین عملکرد را

نشان داد و موفقیت طبقه‌بندی بالاتری نسبت به سایر روش‌ها داشت. بنابراین، مدل روش پیشنهادی به‌عنوان مناسب‌ترین راه‌حل برای طبقه‌بندی صداهای نوزاد انتخاب شد.

نرخ دقت ۹۰٪ به‌دست‌آمده با مطالعه‌ای که بهترین نتیجه شناخته‌شده را در ادبیات داشت، مقایسه شد. با توجه به نتایج جدول ۷، روش پیشنهادی موفق‌ترین نتیجه را در همان نوع تقسیم‌بندی داده پشت سر گذاشت.

جدول ۷. مطالعات مقایسه‌ای بر روی Donate a Cry و نرخ‌های دقت

نویسندگان	تکنیک‌ها	نمره F1	دقت
جمال و همکاران	ANN	۹۹٪/۴۶	۹۳٪/۸۵
روش ما	ANN + GS + DA + MFCC	۹۰٪	۹۰٪


شباهت‌ها و تفاوت‌های بین روش پیشنهادی برای طبقه‌بندی صداهای نوزاد و مطالعات موجود با استفاده از همان فرآیند استخراج ویژگی در جدول ۸ نشان داده شده است.

در این مطالعه، عملکرد روش پیشنهادی با استفاده از ماتریس درهم‌ریختگی، منحنی‌های یادگیری و منحنی‌های ROC به‌تفصیل ارزیابی شد. ماتریس درهم‌ریختگی برای نتایج داده‌های آزمون در شکل ۵ ارائه شده است. نمودار اندازه‌گیری بهترین عملکرد مدل یادگیری در طول دوره یا تکرار در شکل‌های ۶ و ۷ نشان داده شده است.


از ماتریس درهم‌ریختگی برای ارزیابی نرخ‌های دقت و خطای مبتنی بر طبقه مدل بر اساس داده‌های آزمون استفاده شد. اکثر طبقات به‌درستی طبقه‌بندی شدند. نرخ‌های طبقه‌بندی صحیح به‌ویژه برای درد شکم، آروغ زدن و ناراحتی بالا بود (به‌ترتیب ۳۱، ۱۶ و ۴۹ طبقه‌بندی صحیح). سردرگمی قابل‌توجهی بین گرسنه و خسته مشاهده شد. گرسنه اغلب به‌عنوان خسته طبقه‌بندی اشتباه می‌شد (۵ مثال) و به‌طور مشابه، خسته در ۷ مثال به‌عنوان گرسنه پیش‌بینی شد. این وضعیت نشان می‌دهد که ویژگی‌های این طبقات می‌تواند کاملاً مشابه باشد.

منحنی‌های یادگیری نشان‌دهنده تغییرات دقت آموزش و اعتبارسنجی مدل در طول دوره‌ها در شکل ۶ ارائه شده است. مدل برای دقت آموزش، به‌سرعت بر روی داده‌های آموزشی یاد گرفت و به نرخ دقت تقریباً ۹۰٪ رسید. بااین‌حال، این وضعیت نشان می‌دهد که مدل در برابر بیش‌برازش آسیب‌پذیر است. برای دقت اعتبارسنجی، اگرچه دقت بر روی مجموعه داده اعتبارسنجی در ابتدا پایین بود (۳۰ درصد)، زمان افزایش یافت و به تقریباً ۶۰٪ رسید.

با این حال، تفاوت قابل توجه بین دقت آموزش و اعتبارسنجی نشان می‌دهد که مدل در تعمیم‌پذیری بر روی داده‌های اعتبارسنجی ضعیف است.



شکل ۵- ماتریس درهم‌ریختگی برای روش پیشنهادی




شکل ۶ - منحنی‌های یادگیری برای ANN

جدول ۸. مقایسه مطالعات استفاده کننده از استخراج ویژگی MFCC با روش پیشنهادی.

اولین نویسنده	مجموعه داده	ویژگی‌ها	طبقه‌بندی‌کننده‌ها	تفاوت‌ها	شباهت‌ها
لیو [۶]	ضبط‌شده در NICU جلب توجه، گریه، نیاز به تعویض پوشک، گریه و گرسنگی)	LPC, LPCC, MFCC, BFCC	ANN, KNN	مجموعه داده و طبقه‌بندی‌کننده متفاوت	طبقه‌بندی گریه نوزاد؛ روش استخراج ویژگی مشابه
بانو [۱۰]	خودضبط‌شده (گرسنه، نیاز به آروغ، خواب‌آلود، درد، ناراحتی)	MFCC, MFCC	KNN	مجموعه داده و طبقه‌بندی‌کننده متفاوت	طبقه‌بندی گریه نوزاد؛ روش استخراج ویژگی مشابه
باگات‌پاتیل [۱۲]	خودضبط‌شده (درد، گرسنگی، ناراحتی، نیاز به آروغ، درد شکم)	MFCC, LFCC	KNN	مجموعه داده و طبقه‌بندی‌کننده متفاوت	طبقه‌بندی گریه نوزاد؛ روش استخراج ویژگی مشابه
روزالس-پرز [۱۳]	Baby Chillanto (گرسنه در مقابل درد)	LPC, MFCC	مدل فازی	مجموعه داده و طبقه‌بندی‌کننده متفاوت	طبقه‌بندی گریه نوزاد؛ روش استخراج ویژگی مشابه
بشیری [۱۵]	Baby Chillanto	MFCC	ANN	مجموعه داده متفاوت	طبقه‌بندی گریه نوزاد؛ روش استخراج ویژگی و طبقه‌بندی‌کننده مشابه
مانیکانتا [۱۷]	ضبط‌شده در منزل (گریه با کولر، پنکه و غیره)	MFCC	1D-CNN, SVM, FFNN	تشخیص گریه نوزاد؛ مجموعه داده و طبقه‌بندی‌کننده متفاوت	روش استخراج ویژگی مشابه
فرتی [۲۰]	مجموعه داده واقعی: ضبط‌شده در NICU بیمارستان؛ مجموعه داده مصنوعی: گریه با گفتار، صداهای «بوق» و غیره	ضرایب Log-Mel	CNN	تشخیص گریه نوزاد؛ مجموعه داده و طبقه‌بندی‌کننده متفاوت	روش استخراج ویژگی مشابه
لاونر [۲۳]	ضبط‌شده در محیط خانه (گریه با گفتار، باز شدن در و غیره)	MFCC, گام زیرویمی، فرمانت و غیره	CNN	تشخیص گریه نوزاد؛ مجموعه داده و طبقه‌بندی‌کننده متفاوت	روش استخراج ویژگی مشابه
جمال و همکاران [۲۴]	Donate و Baby Cry a Cry	انحراف کروماتیک	ANN	روش استخراج ویژگی متفاوت	طبقه‌بندی گریه نوزاد؛ مجموعه داده و طبقه‌بندی‌کننده مشابه

روش پیشنهادی	Donate a Cry	MFCC	ANN	تکنیک‌های افزایش داده؛ بهینه‌سازی فرآپارامتر	طبقه‌بندی گریه نوزاد؛ مجموعه داده، طبقه‌بندی‌کننده و روش استخراج ویژگی مشابه
--------------	--------------	------	-----	---	---



شکل ۷- منحنی ROC برای ANN

منحنی ROC ارائه شده در شکل ۷ برای ارزیابی قدرت تفکیک بین طبقاتی مدل استفاده شد. مقادیر AUC برای تمام طبقات کاملاً بالا است (۹۹/۰ برای درد شکم، ۰/۱ برای آروغ زدن، ۹۹/۰ برای ناراحتی، ۹۵/۰ برای گرسنه و ۹۸/۰ برای خسته)، که نشان می‌دهد مدل به‌طور کلی قدرت تفکیک خوبی دارد. در محاسبه منحنی‌های ROC از رویکرد One-vs-Rest (OvR) استفاده شد.

کاهش‌های جزئی در مقادیر AUC به‌ویژه برای گرسنه و خسته (به‌ترتیب ۹۵/۰ و ۹۸/۰)، نشان‌دهنده نتیجه‌ای سازگار با سردرگمی بین این طبقات است. مهندسی ویژگی و/یا متعادل‌سازی مجموعه داده برای جداسازی بهتر این طبقات توصیه می‌شود.

برای تحلیل استحکام روش پیشنهادی در این مقاله، روش اعتبارسنجی متقابل ۱۰-تایی (۱۰-fold cross-validation) نیز اعمال شد. مجموعه داده به ۱۰ زیرمجموعه مختلف تقسیم شد و مدل در هر یک از آنها آموزش و آزمایش شد. پس از اتمام آموزش مدل در هر لایه، پیش‌بینی‌ها بر روی مجموعه اعتبارسنجی انجام شد

و برجسب‌های طبقه پیش‌بینی شده ذخیره شدند. در نهایت، عملکرد کلی مدل با ترکیب نتایج تمام لایه‌ها محاسبه شد.

نتایج، عملکرد مدل را در برابر طبقات مختلف نشان می‌دهد و کیفیت طبقه‌بندی را اندازه‌گیری می‌کند. دقت مدل با میانگین دقت محاسبه شده در نتیجه اعتبارسنجی متقابل ارائه شده است. در نتیجه اعتبارسنجی متقابل ۱۰- تایی، نرخ دقت ۸۷٪ به دست آمد.

۴. نتیجه‌گیری

در این مقاله، مدل‌های مختلف هوش مصنوعی برای طبقه‌بندی صداها و نوزاد اعمال و آزمایش شدند. عملکرد مدل‌های VGG16 از پیش‌آموزش‌دیده، KNN، CNN، جنگل تصادفی و شبکه عصبی مصنوعی (ANN) با استفاده از مجموعه داده Donate a Cry ارزیابی شد. نرخ موفقیت مدل‌ها به لطف بهینه‌سازی‌های فرارامتر انجام شده با الگوریتم جستجوی شبکه‌ای افزایش یافت. نتایج نشان داد که دقت آزمون در روش پیشنهادی، به‌ویژه با استفاده از یک شبکه عصبی مصنوعی (ANN) پنج لایه، به ۹۰٪ رسید. این نرخ موفقیت، اثربخشی روش‌های یادگیری عمیق را در طبقه‌بندی صحیح صداها و گریه نوزاد نشان می‌دهد.

نتایج مهم مطالعه شامل اثربخشی مدل‌های هوش مصنوعی، تکنیک‌های پردازش داده و روش‌های افزایش داده است. روش پیشنهادی دقت بالایی در طبقه‌بندی صداها و نوزاد ارائه داد. علاوه بر این، ویژگی‌هایی مانند ضرایب کپسترالی مل-فرکانسی (MFCC)، ویژگی‌های حوزه زمان و طیف به‌طور قابل‌توجهی

عملکرد طبقه‌بندی را افزایش دادند. تکنیک‌های افزایش داده مانند جابه‌جایی زمانی، تغییر گام زیربومی و افزودن نویز سفید، مجموعه داده را غنی‌تر کرده و توانایی تعمیم‌پذیری مدل را تقویت کردند.

نتایج این مطالعه کاربردهای بالقوه‌ای در خدمات بهداشتی و مراقبت از نوزاد دارد. به‌ویژه، می‌تواند به توسعه سیستم‌های بلادرنگ که می‌توانند صداها و گریه نوزاد را تحلیل کرده و اطلاعات سریع و دقیقی به والدین یا متخصصان مراقبت‌های بهداشتی ارائه دهند، کمک کنند.

کارهای آینده می‌توانند بر روی آزمایش مدل‌ها با استفاده از مجموعه داده‌های بزرگ‌تر و توسعه سیستم‌های بهینه شده برای کاربردهای بلادرنگ متمرکز شوند. علاوه بر این، استفاده از ویژگی‌های آکوستیکی مختلف و معماری‌های پیشرفته‌تر یادگیری عمیق می‌تواند عملکرد طبقه‌بندی را بیشتر بهبود بخشد.

اختصارات

اختصارات زیر در این نسخه خطی استفاده شده است:

معنی کامل	اختصار
شبکه عصبی مصنوعی	ANN
مساحت زیر منحنی	AUC
ضرایب کپسترالی فرکانس بارک	BFCCs
شبکه عصبی پیچشی	CNN
مجموعه داده تشخیص احساسات و تشخیص گریه نوزاد	CRIED
شبکه عصبی پیچشی بازگشتی	CRNN
جعبه‌ابزار CUDA نسخه ۲/۱۱	cu112
افزایش داده	DA
تبدیل کسینوسی گسسته	DCT
فرکانس بنیادی	F0
فرکانس‌های فرمانت اول، دوم و سوم	F123
تبدیل فوریه سریع	FFT
جستجوی شبکه‌ای	GS
k-نزدیک‌ترین همسایه‌ها	KNN
ضریب کپسترالی فرکانس خطی	LFCC
کدنویسی پیش‌بینی خطی	LPC
ضریب کپسترالی پیش‌بینی خطی	LPCC
فعال‌سازی لگاریتمی Softmax	LogSoftmax
جنگل تصادفی، افزایش داده، ضرایب کپسترالی مل-فرکانسی	M1
یکی در برابر همه، افزایش داده، صافی طیفی	M2
k-نزدیک‌ترین همسایه‌ها، افزایش داده، صافی طیفی	M3
شبکه عصبی پیچشی، ضرایب کپسترالی مل-فرکانسی	M4
شبکه VGG16 لایه‌ای، ضرایب کپسترالی مل-فرکانسی	M5
Alexnet، تقسیم داده، ضریب کپسترالی مل-فرکانسی	M6
ضریب کپسترالی مل-فرکانسی	MFCC
بخش مراقبت‌های ویژه نوزادان	NICU

References

1. Lahti, K.; Vänskä, M.; Qouta, S.R.; Diab, M.Y.; Perko, K.; Punamäki, R.L. Maternal experience of their infants' crying in the context of war trauma: Determinants and consequences. *Infant Ment. Health J.* **2019**, *40*, 717–734. [[CrossRef](#)] [[PubMed](#)]
2. Halpern, R.; Coelho, R. Excessive crying in infants. *J. Pediatr.* **2016**, *92*, S40–S45. [[CrossRef](#)]
3. Sharma, K.; Gupta, C.; Gupta, S. Infant weeping calls decoder using statistical feature extraction and Gaussian mixture models. In Proceedings of the 2019 10th International Conference on Computing, Communication and Networking Technologies (ICCCNT), Kanpur, India, 6–8 July 2019; pp. 1–6. [[CrossRef](#)]
4. Maghfira, T.N.; Basaruddin, T.; Krisnadhi, A. Infant cry classification using CNN-RNN. *J. Phys. Conf. Ser.* **2020**, *1528*, 012019. [[CrossRef](#)]
5. Franti, E.; Ispas, I.; Dascalu, M. Testing the Universal Baby Language hypothesis - automatic infant speech recognition with CNNs. In Proceedings of the 2018 41st International Conference on Telecommunications and Signal Processing (TSP), Athens, Greece, 4–6 July 2018; pp. 1–4. [[CrossRef](#)]
6. Liu, L.; Li, Y.; Kuo, K. Infant cry signal detection, pattern extraction and recognition. In Proceedings of the 2018 International Conference on Information and Computer Technologies (ICICT), DeKalb, IL, USA, 23–25 March 2018; pp. 159–163. [[CrossRef](#)]
7. Turan, M.A.T.; Erzin, E. Monitoring infant's emotional cry in domestic environments using the capsule network architecture. In Proceedings of the Annual Conference of the International Speech Communication Association (INTERSPEECH), Hyderabad, India, 2–6 September 2018. [[CrossRef](#)]
8. Osmani, A.; Hamidi, M.; Chibani, A. Machine learning approach for infant cry interpretation. In Proceedings of the International Conference on Tools with Artificial Intelligence (ICTAI), Volos, Greece, 5–7 November 2018. [[CrossRef](#)]
9. Chang, C.Y.; Li, J.J. Application of deep learning for recognizing infant cries. In Proceedings of the 2016 IEEE International Conference on Consumer Electronics-Taiwan (ICCE-TW), Nantou County, Taiwan, 27–29 May 2016; pp. 1–2. [[CrossRef](#)]
10. Bano, S.; Ravikumar, K.M. Decoding baby talk: A novel approach for normal infant cry signal classification. In Proceedings of the IEEE International Conference on Soft-Computing and Network Security (ICSNS), Coimbatore, India, 25–27 February 2015; pp. 24–26. [[CrossRef](#)]
11. Orlandi, S.; Garcia, C.A.R.; Bandini, A.; Donzelli, G.; Manfredi, C. Application of pattern recognition techniques to the classification of full-term and preterm infant cry. *J. Voice* **2016**, *30*, 656–663. [[CrossRef](#)] [[PubMed](#)]
12. Bhagatpatil, M.V.V. An automatic infant's cry detection using linear frequency cepstrum coefficients (LFCC). *Int. J. Sci. Eng. Res.* **2014**, *5*, 1379–1383.
13. Rosales-Pérez, A.; Reyes-García, C.A.; Gonzalez, J.A.; Reyes-Galaviz, O.F.; Escalante, H.J.; Orlandi, S. Classifying infant cry patterns by the Genetic Selection of a Fuzzy Model. *Biomed. Signal Process. Control* **2015**, *17*, 38–46. [[CrossRef](#)]
14. Yamamoto, S.; Yoshitomi, Y.; Tabuse, M.; Kushida, K.; Asada, T. Recognition of a baby's emotional cry towards robotics baby caregiver. *Int. J. Adv. Robot. Syst.* **2013**, *10*, 86. [[CrossRef](#)]
15. Bashiri, A.; Hosseinkhani, R. Infant Crying Classification by Using Genetic Algorithm and Artificial Neural Network. *Acta Medica Iran.* **2020**, *58*, 531–539. [[CrossRef](#)]
16. Chang, C.Y.; Tsai, L.Y. A CNN-based method for infant cry detection and recognition. In Proceedings of the Workshops of the International Conference on Advanced Information Networking and Applications, Matsue, Japan, 27–29 March 2019. [[CrossRef](#)]
17. Manikanta, K.; Soman, K.P.; Manikandan, M.S. Deep learning based effective baby crying recognition method under indoor background sound environments. In Proceedings of the 2019 4th International Conference on Computational Systems and Information Technology for Sustainable Solution (CSITSS), Bengaluru, India, 20–21 December 2019; Volume 4, pp. 1–6. [[CrossRef](#)]
18. Dewi, S.P.; Prasasti, A.L.; Irawan, B. Analysis of LFCC feature extraction in baby crying classification using KNN. In Proceedings

- of the 2019 IEEE International Conference on Internet of Things and Intelligence System (IoTaIS), Bali, Indonesia, 5–7 November 2019; pp. 86–91. [\[CrossRef\]](#)
19. Gu, G.; Shen, X.; Xu, P. A set of DSP system to detect baby crying. In Proceedings of the 2018 2nd IEEE Advanced Information Management, Communication, Electronic and Automation Control Conference (IMCEC), Xi'an, China, 25–27 May 2018; pp. 411–415. [\[CrossRef\]](#)
 20. Ferretti, D.; Severini, M.; Principi, E.; Cenci, A.; Squartini, S. Infant cry detection in adverse acoustic environments by using deep neural networks. In Proceedings of the 2018 26th European Signal Processing Conference (EUSIPCO), Roma, Italy, 3–7 September 2018; pp. 992–996. [\[CrossRef\]](#)
 21. Robu, R.; Feier, F.; Stoicu-Tivadar, V.; Ilie, C.; Enatescu, I. The analysis of the new-borns' cry using NEONAT and data mining techniques. In Proceedings of the 2011 15th IEEE International Conference on Intelligent Engineering Systems (INES), Poprad, Slovakia, 23–25 June 2011; pp. 235–238. [\[CrossRef\]](#)
 22. Torres, R.; Battaglini, D.; Lepauloux, L. Baby cry sound detection: A comparison of hand crafted features and deep learning approach. In Proceedings of the International Conference on Engineering Applications of Neural Networks, Athens, Greece, 25–27 August 2017. [\[CrossRef\]](#)
 23. Lavner, Y.; Cohen, R.; Ruinskiy, D.; Ijzerman, H. Baby cry detection in domestic environment using deep learning. In Proceedings of the 2016 IEEE International Conference on the Science of Electrical Engineering (ICSEE), Eilat, Israel, 16–18 November 2016. [\[CrossRef\]](#)
 24. Jamal, A.; Al-Azani, S. A Machine-Learning Approach for Children's Pain Assessments Using Prosodic and Spectral Acoustic Features. In Proceedings of the 2023 3rd International Conference on Electrical, Computer, Communications and Mechatronics Engineering (ICECCME), Online, 20–21 July 2023; pp. 1–6.
 25. Veres, G. DonateACry Corpus: An Open-Source Dataset for Infant Cry Classification. 2025. Available online: <https://github.com/gveres/donateacry-corpus> (accessed on 5 January 2025).
 26. McFee, B.; McVicar, M.; Faronbi, D.; Roman, I.; Gover, M.; Balke, S.; Seyfarth, S.; Malek, A.; Raffel, C.; Lostanlen, V. et al. librosa/librosa: 0.10.0.post2. 2023. Available online: <https://zenodo.org/record/591533> (accessed on 9 February 2025).
 27. Dewi, S.P.; Prasasti, A.L.; Irawan, B. The Study of Baby Crying Analysis Using MFCC and LFCC in Different Classification Methods. In Proceedings of the 2019 IEEE International Conference on Signals and Systems (ICSigSys), Bandung, Indonesia, 16–18 July 2019; pp. 18–23. [\[CrossRef\]](#)
 28. Saini, N. Voice Recognition Technique: A Review. *Int. J. Res. Appl. Sci. Eng. Technol. (IJRASET)* **2017**, *5*, 262–268.
 29. Koustav Chakraborty, A.T.; Upadhyay, P.S. Voice Recognition Using MFCC Algorithm. *Int. J. Innov. Res. Adv. Eng. (IJIRAE)* **2014**, *1*, 158–161.
 30. Singh, P.P.; Rani, P. An Approach to Extract Feature Using MFCC. *IOSR J. Eng. (IOSRJEN)* **2014**, *4*, 21–25. [\[CrossRef\]](#)
 31. Dong, J.; Hu, S. The progress and prospects of neural network research. *Inf. Control* **1997**, *26*, 360–368.
 32. Jenkins, B.K.; Tanguay, A.R. *Handbook of Neural Computing and Neural Networks*; MIT Press: Boston, MA, USA, 1995.
 33. Bnlsabi, A. Some analytical solutions to the general approximation problem for feed forward neural networks. *Neural Netw.* **1993**, *6*, 991–996.
 34. Luo, Z.H.; Xie, Y.; Zhu, C. The study of convergence of CMAC learning process. *Acta Autom. Sin.* **1997**, *23*, 455–461.
 35. Balcazar, J. Computational power of neural networks: A characterization in terms of Kolmogorov complexity. *IEEE Trans. Inf. Theory* **1997**, *43*, 1175–1183. [\[CrossRef\]](#)
 36. Setiono, R.; Leow, W.K. FERNN: An algorithm for fast extraction of rules from neural networks. *Appl. Intell.* **2000**, *12*, 15–25. [\[CrossRef\]](#)
 37. Toprak, A.N.; Aruk, I. A Hybrid Convolutional Neural Network Model for the Classification of Multi-Class Skin Cancer. *Int. J. Imaging Syst. Technol.* **2024**, *34*, e23180. [\[CrossRef\]](#)